IPCA INSTITUTO POLITÉCNICO DO CÁVADO E DO AVE

Integração de Sistemas de Informação

Licenciatura em Engenharia de Sistemas Informáticos

2026/27

Trabalho Prático I

Rui Barbosa

Nº31515

https://github.com/ruibarbosa04/tp01-31515.git

Conteúdo

1. Enquadramento 4
1.1Equipa, Unidade Curricular e Curso 4
1.2 Estrutura do Documento 4
2.Problema 5
2.1 Contexto 5
2.2 Descrição do problema 5
2.3 Objetivos 5
2.4 Dados Utilizados 5
3.Estratégia utilizada 6
3.1 Arquitetura da Solução 6
3.2 Ferramentas 6
3.3 Modelo da Tabela de Destino 6
3.4 Operadores Utilizados 7
3.5Organização do Repositório 8
3.6 Decisões Comuns de Implementação 8
4. Transformações 9
4.1 Transformação 02 9
4.2 Transformação 03 – Enriquecer, classificar e carregar 12
5. Jobs 16
5.1 Job Principal 16
5.2 Tratamento de Erros 17
5.3 Serviços Remotos: Email 17
5.4 Logs 18
5.5 Agendamento 18
6.Demonstração 18
6.1 Dashboard 19
7. Conclusão e Trabalhos Futuros 20
7.1 Conclusão 20
7.3 Trabalhos Futuros 20
8. Referências 20

Índice de Tabelas

Tabela 1– Enquadramento do trabalho 4
Tabela 2– Fontes de dados 5
Tabela 3– Ferramentas utilizadas 6
Tabela 4-Colunas da tabela transferencias_eficiencia (resumo) 7
Tabela 5– Operadores utilizados 7
Tabela 6– Estrutura do repositório 8
Tabela 7– Transformação 02_join_transfers_appearances no Spoon 9
Tabela 8– Métricas calculadas 10
Tabela 9– Resultados da execução da transformação 02 11
Tabela 10– Passos da transformação 03 12
Tabela 11– Expressões regulares 13
Tabela 12– Regras de classificação 14
Tabela 13– Resultados da execução da transformação 03 15
Tabela 14– Problemas de qualidade e respetivo tratamento 16
Tabela 15– Entradas do job principal 17

Índice de figuras

Figura 1– Transformação 02_join_transfers_appearances no Spoon 9
Figura 2– Linhas lidas e escritas por passo 10
Figura 3– Resultado da transformação 02 11
Figura 4– Transformação 03_enriquecer_ligas no Spoon 12
Figura 5– Dados do XML antes da limpeza 13
Figura 6– Dados do XML depois da limpeza 13
Figura 7– Passo de classificação 14
Figura 8– Codigo para a classificação 14
Figura 9– Resultado da transformação 03 15
Figura 10– Tabela carregada no MySQL Workbench 15
Figura 11– Job principal no Spoon 16
Figura 12– Email enviado pelo job 17
Figura 13– Execução do job 18
Figura 14– Dashboard no Power BI 19

1. Enquadramento

Este relatório documenta o desenvolvimento e a implementação do Trabalho Prático I da unidade curricular de Integração de Sistemas de Informação (ISI): um processo ETL (*Extract*, *Transform*, *Load*) construído com o *Pentaho Data Integration* (*Spoon*), focado no tratamento, integração e análise de dados de transferências de futebol.

1.1Equipa, Unidade Curricular e Curso

Campo	Valor
Aluno	Rui Barbosa (nº 31515)
Docente	Óscar Ribeiro
Unidade Curricular	Integração de Sistemas de Informação
Curso	Licenciatura em Engenharia de Sistemas Informáticos

Tabela 1– Enquadramento do trabalho

1.2 Estrutura do Documento

Para além deste capítulo introdutório, o presente relatório encontra-se estruturado da seguinte forma:

- **Capítulo 2 — Problema e Objetivos:** Apresenta a contextualização do caso de estudo, definindo o problema abordado e os objetivos principais delineados para o projeto.
- **Capítulo 3 — Estratégia, Ferramentas e Decisões:** Detalha a arquitetura adotada, as ferramentas tecnológicas selecionadas e as principais opções de conceção assumidas ao longo do desenvolvimento.
- **Capítulo 4 — Transformações de ETL:** Descreve em detalhe a implementação técnica das transformações desenvolvidas no Pentaho Data Integration, cobrindo o tratamento, cruzamento e enriquecimento dos dados.
- **Capítulo 5 — Orquestração (Job Principal):** Explica o funcionamento do job de controlo responsável por encadear e automatizar a execução sequencial do processo de ETL.
- **Capítulo 6 — Demonstração Prática:** Remete para o vídeo de demonstração que comprova a execução e o comportamento operacional da solução implementada.
- **Capítulo 7 — Conclusão e Trabalhos Futuros:** Apresenta um balanço crítico do trabalho realizado, refletindo sobre as principais dificuldades encontradas e sugerindo perspetivas de melhoria futura.
- **Capítulo 8 — Referências**

2.Problema

2.1 Contexto

Os clubes de futebol pagam valores muito diferentes por transferências, mas o retorno desportivo nem sempre acompanha o custo. Os dados públicos do *Transfermarkt* permitem comparar o que cada clube pagou com o que o jogador produziu no primeiro ano no novo clube.

2.2 Descrição do problema

Os dados vêm dispersos por quatro ficheiros CSV (transferências, jogos, jogadores, clubes), mais um XML de ligas e um YAML de limiares. Não existe uma tabela única que relacione o custo de uma transferência com o desempenho nos 365 dias seguintes. Os dados têm ainda problemas de qualidade: transferências futuras, transferências sem valor, ligas com nomes mal formatados e clubes sem liga associada.

2.3 Objetivos

1. Extrair e integrar quatro CSV, um XML e um YAML.
2. Calcular, por transferência, jogos, golos, assistências e minutos no primeiro ano.
3. Derivar métricas de eficiência: custo por jogo, custo por golo ou assistência e valorização do jogador.
4. Classificar cada transferência (Excelente, Boa, Fraca, Muito fraca, Sem contribuições) com limiares configuráveis.
5. Carregar o resultado em *CSV*, *JSON* e *MySQL*, e automatizar tudo num job com envio de email.

2.4 Dados Utilizados

Os dados vêm do *dataset* público *dcaribou/transfermarkt*-datasets. O XML de ligas e o YAML de limiares foram criados para o trabalho.

Ficheiro	Formato	Conteúdo
transfers	CSV	Transferências, com data, clubes e valor pago
appearances	CSV	Jogos de cada jogador: golos, assistências, minutos
players	CSV	Nome, posição, data de nascimento, valores de mercado
clubs	CSV	Nome do clube e código da liga
ligas	XML	Código, nome e país de 31 ligas
limiares	YAML	Limites de custo para a classificação

Tabela 2– Fontes de dados

O ficheiro ligas.xml e o *limiares.yaml* foram escritos por mim, para praticar a leitura de *XML* e *YAML* e para manter os limiares fora das transformações.

3.Estratégia utilizada

A solução tem duas transformações encadeadas por um job: a primeira junta e mede, a segunda enriquece, classifica e carrega.

3.1 Arquitetura da Solução

1. Extração**:** os quatro CSV, o XML das ligas e o YAML dos limiares.
2. Transformação 02**:** filtra as transferências, junta os jogos do primeiro ano no novo clube e calcula as métricas. Escreve transferencias_eficiencia.csv.
3. Transformação 03**:** limpa as ligas, junta-as às transferências, classifica e escreve três saídas.
4. Carga**:** CSV final, JSON e tabela *MySQL transferencias*_eficiencia.
5. Job**:** corre as duas transformações por ordem, regista os erros e envia um email com os ficheiros em anexo.

3.2 Ferramentas

Ferramenta	Utilização
Pentaho Data Integration (*Spoon*) 10.2	Transformações e job
MySQL e MySQL Workbench	Base de dados de destino e consultas
Git e GitHub	Controlo de versões num repositório público
Gmail (SMTP, porta 587, TLS)	Envio do email do job
Power BI	dashboard

Tabela 3– Ferramentas utilizadas

3.3 Modelo da Tabela de Destino

O resultado é uma única tabela, transferencias_eficiencia, com 24 colunas e uma linha por transferência. Cada linha liga o jogador, os clubes e a liga às medidas do primeiro ano.

Grupo	Colunas principais
Identificação	player_id, nome_jogador, position, sub_position, nome_clube, codigo_liga, nome_liga, pais_liga
Transferência	transfer_date, transfer_season, transfer_fee, market_value_in_eur
Primeiro ano	jogos, golos, assistencias, minutos, golos_e_assistencias
Métricas	custo_por_jogo, custo_por_golo_ou_assistencia, valorizacao

Classificação	classificacao

Tabela 4-Colunas da tabela transferencias_eficiencia (resumo)

3.4 Operadores Utilizados

Operador	Onde	Para quê
CSV file input	02	Ler transfers, appearances, players, clubs
Filter rows	02	Datas futuras, taxa maior que 0, janela de 365 dias
Stream lookup	02	Juntar jogos à transferência (chave jogador + clube) e juntar jogador e clube
Calculator	02	Dias desde a transferência, métricas
Group By	02	Totais de jogos, golos, assistências e minutos por transferência
Append streams	02	Reunir transferências com e sem contribuições
Get data from XML	03	Ler as ligas
Replace in string (RegEx)	03	Reduzir espaços repetidos
String operations	03	Trim e primeira letra maiúscula
If field value is null	03	Liga desconhecida
YAML input e join Rows	03	Ler os limiares e juntá-los a cada linha
User Defined Java Expression	03	Classificação de eficiência
Text file output, JSON output, Table output	03	CSV, JSON e MySQL
Mail, Write to log, Abort	Job	Email, registo e paragem em caso de erro

Tabela 5– Operadores utilizado

3.5Organização do Repositório

Pasta	Conteúdo
data/	ligas.xml, limiares.yaml e data/raw/ (CSV, fora do Git)
Transformations/	Ficheiros .ktr
jobs/	job_transferencias.kjb
output/	CSV e JSON gerados
sql/	Criação da tabela e consultas
docs/	Capturas de ecrã e relatório

Tabela 6– Estrutura do repositório

3.6 Decisões Comuns de Implementação

- **Caminhos relativos.** Todos os ficheiros são referidos com ${Internal.Entry.Current.Directory}, por isso o projeto corre em qualquer computador sem editar caminhos.
- **Credenciais fora do projeto.** As passwords do MySQL e do Gmail estão em kettle.properties (MYSQL_PASSWORD, SMTP_USER, SMTP_PASSWORD, EMAIL_DESTINO). O repositório é público, por isso nenhuma credencial entra no Git.
- **Dados brutos fora do Git.** A pasta data/raw/ está no .gitignore, porque os CSV são grandes e podem ser descarregados do conjunto original.
- **Limiares num YAML.** Os limites da classificação ficam em limiares.yaml, para os mudar sem abrir a transformação.
- **Carga repetível.** A tabela MySQL é esvaziada (Truncate) antes de cada carga, e cada execução do job substitui o resultado anterior.
- **Janela completa.** Só entram transferências até 15/10/2025, para garantir que os 365 dias seguintes já aconteceram.

4. Transformações

4.1 Transformação 02

Esta transformação recebe as transferências e os jogos e devolve uma linha por transferência, com os totais do primeiro ano e as métricas de custo.

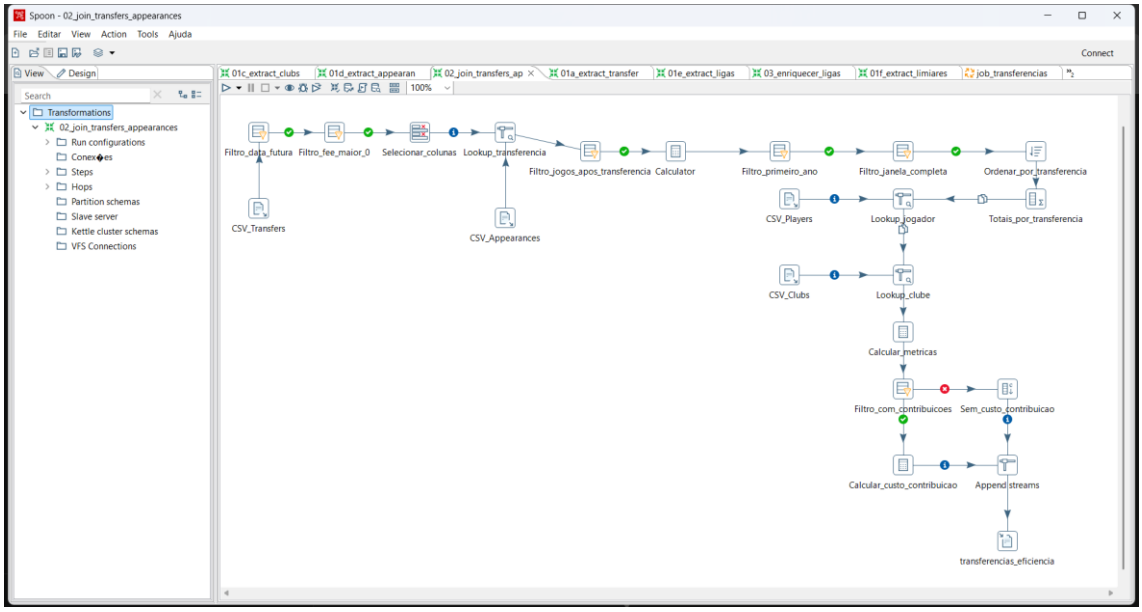


Figura 1– Transformação 02_join_transfers_appearances no Spoon

Nº	Passo	Tipo	Função
1	CSV_Transfers	CSV file input	Lê o ficheiro de transferências
2	Filtro_data_futura	Filter rows	Mantém transferências com data até 09/10/2026
3	Filtro_fee_maior_0	Filter rows	Mantém só transferências pagas (taxa maior que 0)
4	Selecionar_colunas	Select values	Fica com 6 colunas
5	Lookup_transferencia	Stream lookup	Junta cada jogo à transferência pela chave jogador + clube de destino
6	Filtro_jogos_apos_transferencia	Filter rows	Descarta jogos sem transferência ou anteriores à data
7	Calculator	Calculator	Calcula dias_desde_transferencia (data do jogo menos data da transferência)
8	Filtro_primeiro_ano	Filter rows	Mantém jogos até 365 dias depois
9	Filtro_janela_completa	Filter rows	Mantém transferências até 15/10/2025
10	Ordenar_por_transferencia	Sort rows	Prepara a agregação
11	Totais_por_transferencia	Group By	Soma jogos, golos, assistências e minutos
12	Lookup_jogador	Stream lookup	Acrescenta nome, posição e valores de mercado
13	Lookup_clube	Stream lookup	Acrescenta nome do clube e código da liga
14	Calcular_metricas	Calculator	Golos e assistências, custo por jogo e valorização

15	Filtro_com_contribuicoes	Filter rows	Separa as linhas com e sem golos ou assistências
16	Calcular_custo_contribuicao	Calculator	Custo por golo ou assistência (taxa a dividir por golos e assistências)
17	Sem_custo_contribuicao	Add constants	Preenche o custo com nulo nas linhas sem contribuições
18	Append streams	Append streams	Volta a juntar os dois ramos
19	transferencias_eficiencia	Text file output	Escreve transferencias_eficiencia.csv

Tabela 7– Passos da transformação 02

O Stream lookup usa chave composta (jogador e clube) porque o mesmo jogador aparece em vários clubes. Sem o clube, os jogos de um clube antigo seriam contados no novo.

Métrica	Cálculo
golos_e_assistencias	golos + assistências
custo_por_jogo	taxa de transferência / jogos
custo_por_golo_ou_assistencia	taxa de transferência / golos_e_assistencias (nulo se for 0)
valorizacao	Valor de mercado atual – taxa de transferência

Tabela 8– Métricas calculadas

Execution Results

Logging | Execution History | Step Metrics | Performance Graph | Metrics | Preview data

#	Nome do step	Copia nr	Lidos	escritos	Entrada	Sa&#65533;da	Atualizados	Rejected	Erros	Ativo	Tempo	Velocidade (r/s)	Pri/ent/sai
1	CSV_Transfers	0	0	175157	175158	0	0	0	0	Finished	1.0s	169.562	-
2	CSV_Clubs	0	0	796	797	0	0	0	0	Finished	0.1s	8.479	-
3	Filtro_data_futura	0	175157	174690	0	0	0	0	0	Finished	1.0s	168.745	-
4	Filtro_fee_maior_0	0	174690	17553	0	0	0	0	0	Finished	1.0s	167.328	-
5	CSV_Appearances	0	0	1894350	1894351	0	0	0	0	Finished	5.1s	374.896	-
6	Selecionar_colunas	0	17553	17553	0	0	0	0	0	Finished	1.1s	16.701	-
7	CSV_Players	0	0	50149	50150	0	0	0	0	Finished	0.8s	66.074	-
8	Lookup_transferencia	0	1911903	1894350	0	0	0	0	0	Finished	5.1s	378.071	-
9	Filtro_jogos_apos_transferencia	0	1894350	550469	0	0	0	0	0	Finished	5.1s	374.156	-
1..	Calculator	0	550469	550469	0	0	0	0	0	Finished	5.1s	108.595	-
1..	Filtro_primeiro_ano	0	550469	200399	0	0	0	0	0	Finished	5.1s	108.467	-
1..	Filtro_janela_completa	0	200399	197846	0	0	0	0	0	Finished	5.1s	39.464	-
1..	Ordenar_por_transferencia	0	197846	197846	0	0	0	0	0	Finished	5.6s	35.254	-
1..	Totais_por_transferencia	0	197846	8430	0	0	0	0	0	Finished	5.6s	35.166	-
1..	Lookup_jogador	0	58579	8430	0	0	0	0	0	Finished	5.6s	10.401	-
1..	Lookup_clube	0	9226	8430	0	0	0	0	0	Finished	5.6s	1.637	-
1..	Calcular_metricas	0	8430	8430	0	0	0	0	0	Finished	5.6s	1.494	-
1..	Filtro_com_contribuicoes	0	8430	8430	0	0	0	0	0	Finished	5.6s	1.492	-
1..	Sem_custo_contribuicao	0	2271	2271	0	0	0	0	0	Finished	5.7s	402	-
2..	Calcular_custo_contribuicao	0	6159	6159	0	0	0	0	0	Finished	5.7s	1.090	-
2..	Append streams	0	8430	8430	0	0	0	0	0	Finished	6.0s	1.415	-
2..	transferencias_eficiencia	0	8430	8430	0	8431	0	0	0	Finished	6.0s	1.414	-

Figura 2– Linhas lidas e escritas por passo

Passo	Linhas
Transferências lidas	175 157
Depois de Filtro_data_futura	174 690
Depois de Filtro_fee_maior_0	17 553
Jogos depois do Lookup e Filtro_jogos_apos_transferencia	550 469
Jogos depois de Filtro_primeiro_ano	200 399
Transferências depois de Totais_por_transferencia	8 430
Linhas escritas no CSV	8 431

Tabela 9– Resultados da execução da transformação 02

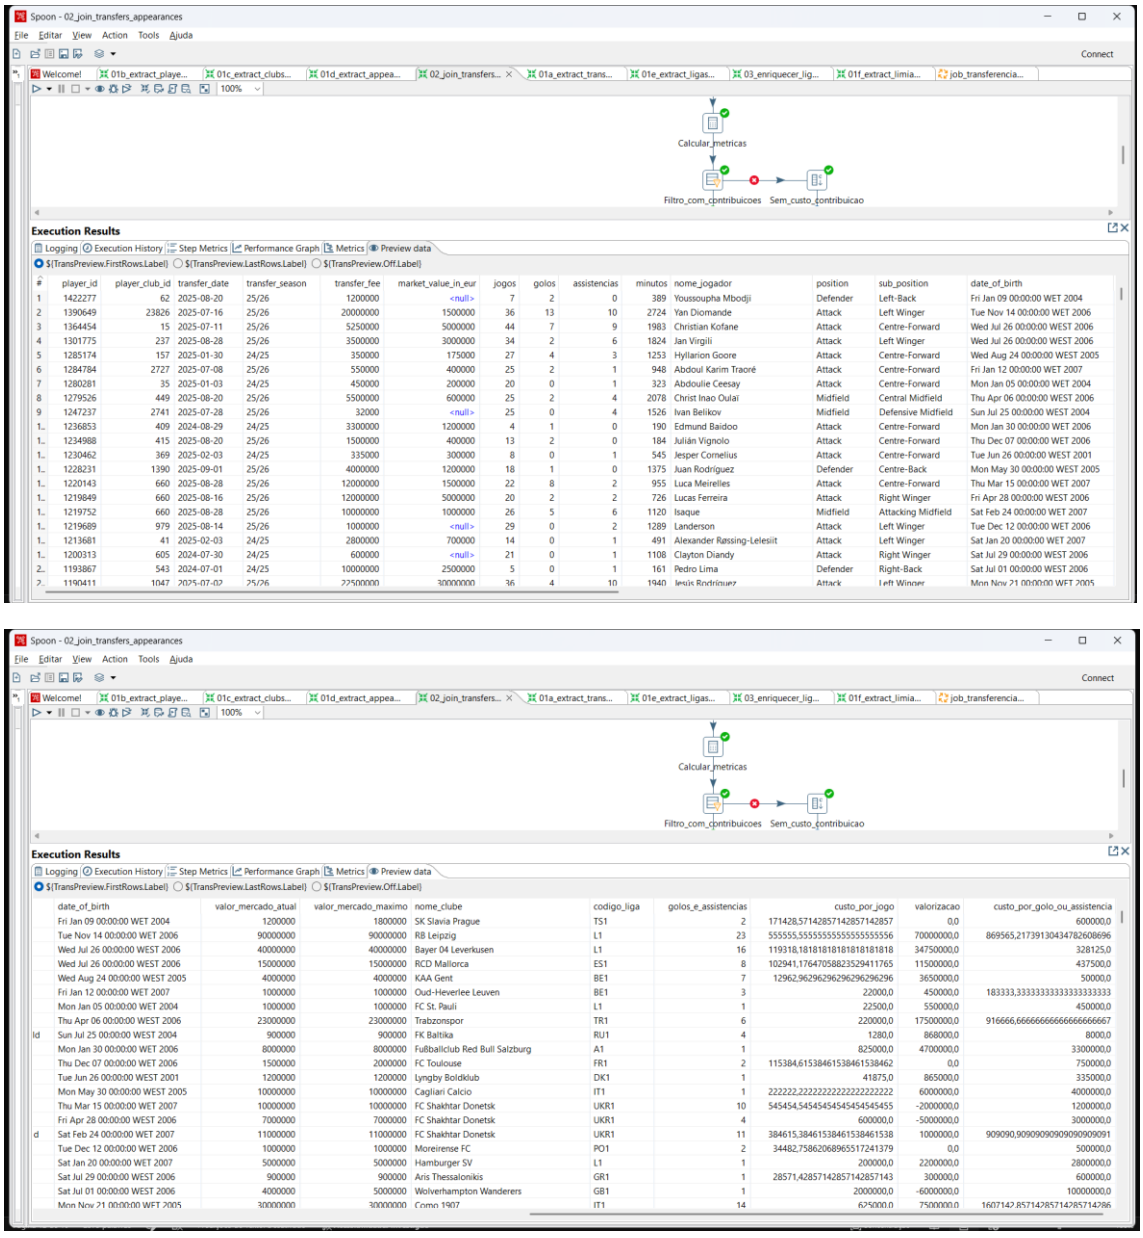


Figura 3– Resultado da transformação 02

4.2 Transformação 03 – Enriquecer, classificar e carregar

Esta transformação lê o resultado da 02, junta as ligas (XML) e os limiares (YAML), classifica cada transferência e escreve três saídas.

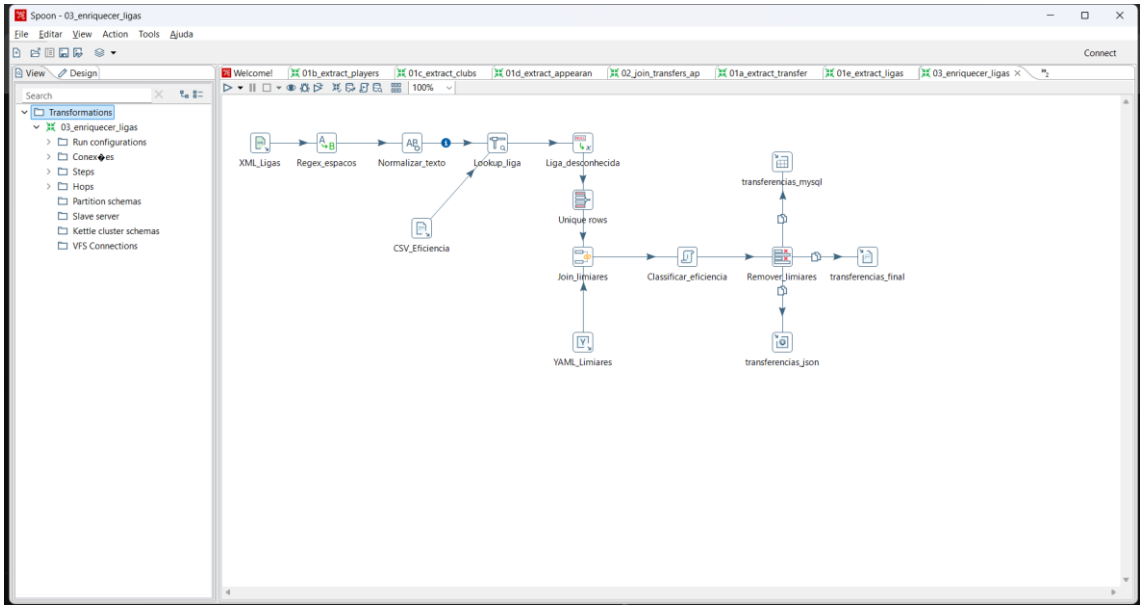


Figura 4– Transformação 03_enriquecer_ligas no Spoon

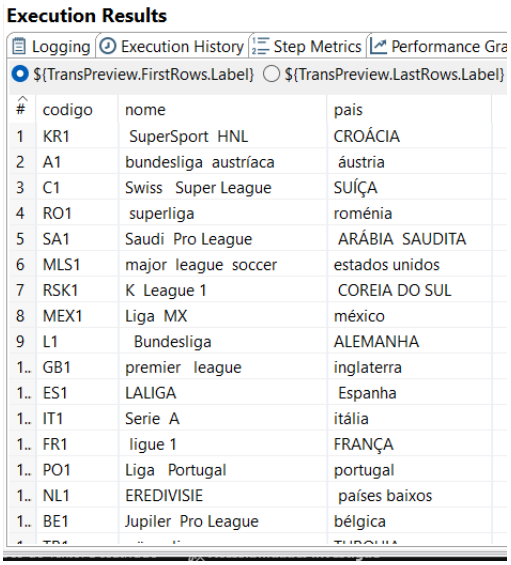
Nº	Passo	Tipo	Função
1	XML_Ligas	Get data from XML	Lê as 31 ligas de ligas.xml
2	Regex_espacos	Replace in string	Troca dois ou mais espaços seguidos por um
3	Normalizar_texto	String operations	Trim dos dois lados e primeira letra maiúscula
4	Lookup_liga	Stream lookup	Junta nome e país da liga pelo código
5	Liga_desconhecida	If field value is null	Preenche "Desconhecida" quando não há liga
6	Unique rows	Unique rows	Remove linhas repetidas
7	Join_limiares	Join Rows	Acrescenta os três limiares a cada linha
8	Classificar_eficiencia	User Defined Java Expression	Calcula a classificação
9	Remover_limiares	Select values	Remove os três campos de limiar
10	transferencias_final	Text file output	Escreve o CSV final
11	transferencias_json	JSON output	Escreve o JSON (bloco data)
12	transferencias_mysql	Table output	Carrega a tabela MySQL com Truncate

Tabela 10– Passos da transformação 03

O passo Unique rows foi uma fonte de erro: ao comparar poucos campos, apagava transferências válidas. Depois de corrigido, a transformação deixa passar as 8 430 linhas.

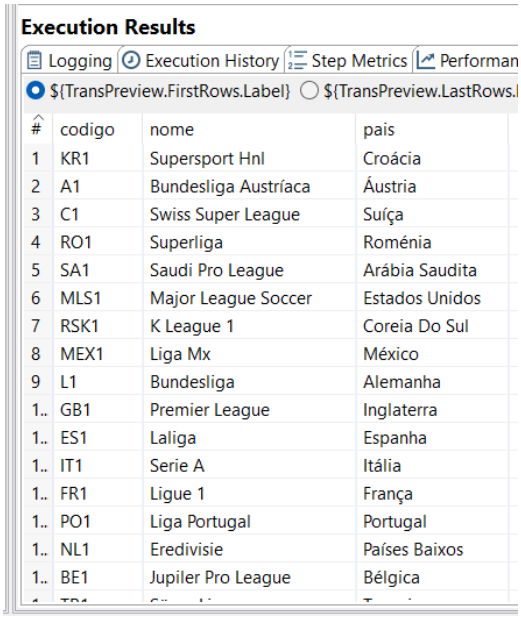
Expressão	Passo	Efeito
\s{2,}	Regex_espacos	Dois ou mais espaços seguidos passam a um só

Tabela 11– Expressões regulares



#	codigo	nome	pais
1	KR1	SuperSport HNL	CROÁCIA
2	A1	bundesliga austríaca	áustria
3	C1	Swiss Super League	SUÍÇA
4	RO1	superliga	roménia
5	SA1	Saudi Pro League	ARÁBIA SAUDITA
6	MLS1	major league soccer	estados unidos
7	RSK1	K League 1	COREIA DO SUL
8	MEX1	Liga MX	méxico
9	L1	Bundesliga	ALEMANHA
1..	GB1	premier league	inglaterra
1..	ES1	LALIGA	Espanha
1..	IT1	Serie A	itália
1..	FR1	ligue 1	FRANÇA
1..	PO1	Liga Portugal	portugal
1..	NL1	EREDIVISIE	países baixos
1..	BE1	Jupiler Pro League	bélgica

Figura 5– Dados do XML antes da limpeza



#	codigo	nome	pais
1	KR1	Supersport Hnl	Croácia
2	A1	Bundesliga Austríaca	Áustria
3	C1	Swiss Super League	Suíça
4	RO1	Superliga	Roménia
5	SA1	Saudi Pro League	Arábia Saudita
6	MLS1	Major League Soccer	Estados Unidos
7	RSK1	K League 1	Coreia Do Sul
8	MEX1	Liga Mx	México
9	L1	Bundesliga	Alemanha
1..	GB1	Premier League	Inglaterra
1..	ES1	Laliga	Espanha
1..	IT1	Serie A	Itália
1..	FR1	Ligue 1	França
1..	PO1	Liga Portugal	Portugal
1..	NL1	Eredivisie	Países Baixos
1..	BE1	Jupiler Pro League	Bélgica

Figura 6– Dados do XML depois da limpeza

Os limiares vêm de limiares.yaml e a classificação usa o custo por golo ou assistência:

Classificação	Regra
Sem contribuições	Custo nulo (nenhum golo nem assistência)
Excelente	Até 300 000
Boa	Até 1 000 000
Fraca	Até 3 000 000
Muito fraca	Acima de 3 000 000

Tabela 12– Regras de classificação

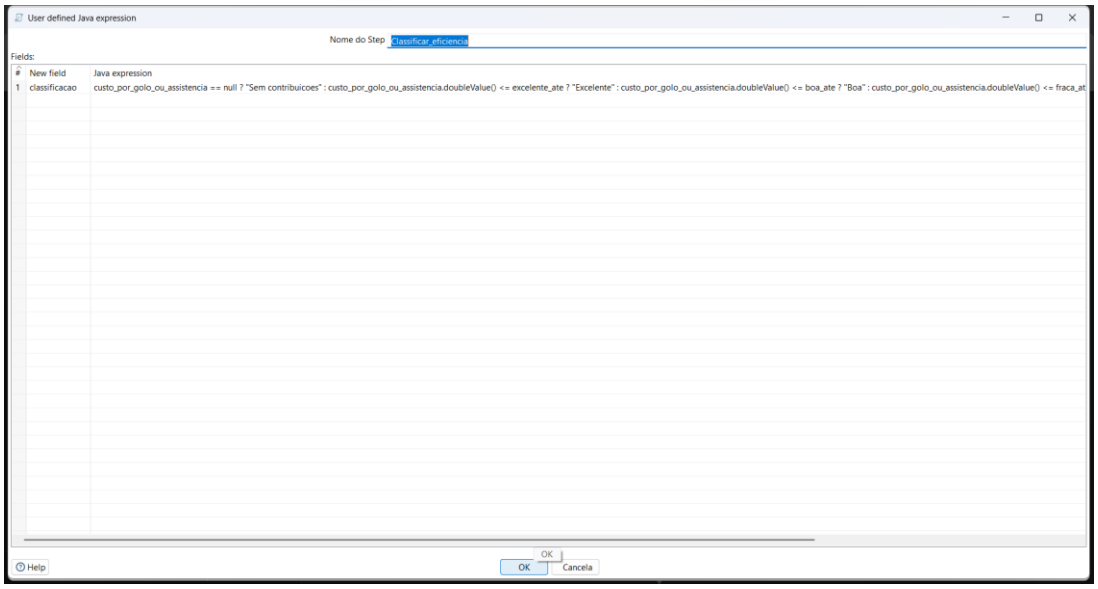


Figura 7– Passo de classificação

```
custo_por_golo_ou_assistencia == null ? "Sem
contribuicoes"
: custo_por_golo_ou_assistencia.doubleValue() <=
excelente_ate ? "Excelente"
: custo_por_golo_ou_assistencia.doubleValue() <=
boa_ate ? "Boa"
: custo_por_golo_ou_assistencia.doubleValue() <=
fraca_ate ? "Fraca"
: "Muito fraca"
```

Figura 8– Codigo para a classificação

Saída	Destino	Linhas
CSV	output/transferencias_final.csv	8 430
JSON	output/ (ficheiro JSON, bloco data)	8 430
MySQL	tabela transferencias_eficiencia	8 430

Tabela 13– Resultados da execução da transformação 03

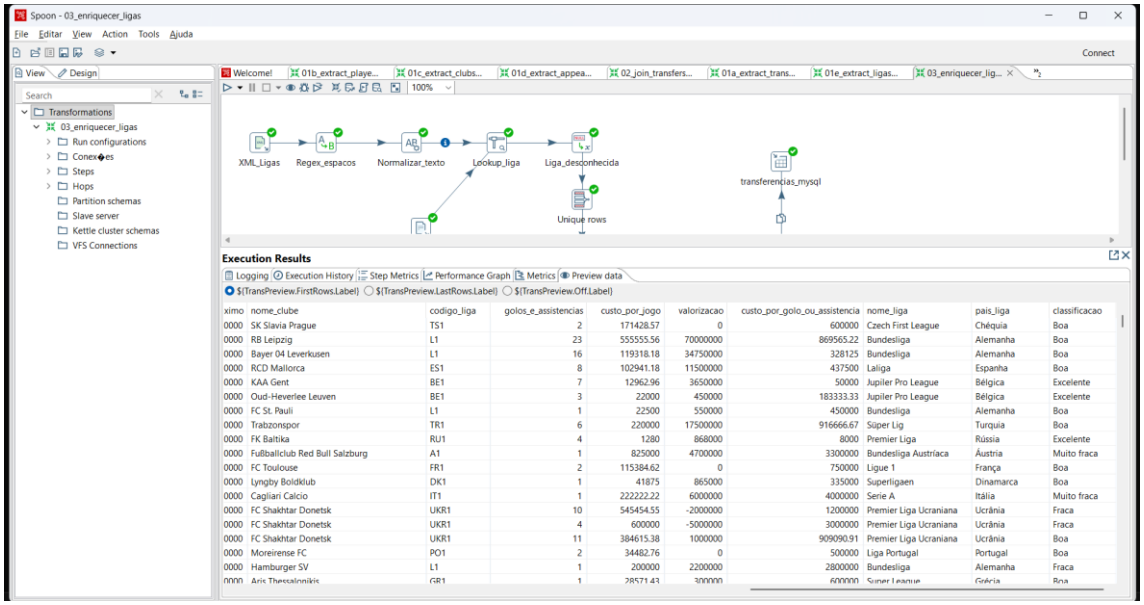


Figura 9– Resultado da transformação 03

Na Figura 15, a coluna classificação surge em último lugar, porque é o último campo calculado na transformação.

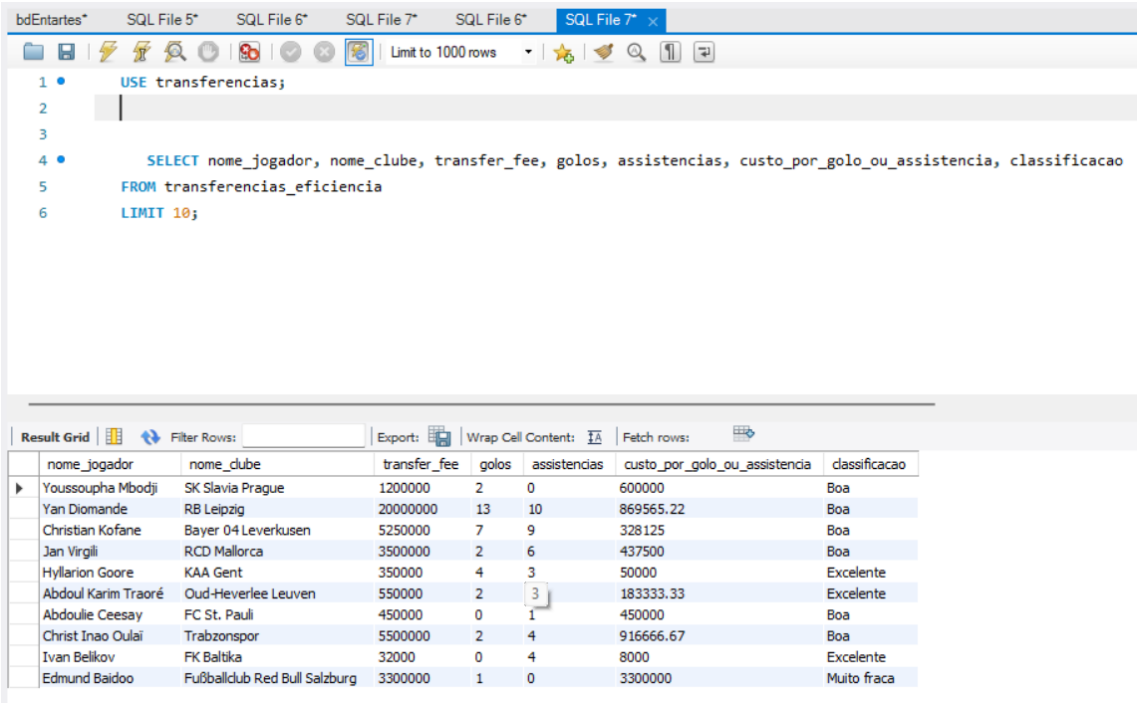


Figura 10– Tabela carregada no MySQL Workbench

4.3 Problemas de Qualidade dos Dados

Problema	Tratamento
Transferencias com data futura	Filtro_data_futura
Transferências sem taxa (gratuitas ou empréstimos)	Filtro_fee_maior_0
Jogos de clubes anteriores ao novo clube	Chave composta jogador + clube e filtro de datas
Nomes de ligas com espaços a mais e maiúsculas	Regex e String operations
Clubes sem código de liga	Liga "Desconhecida"
Campo date_of_birth com formato inválido na saída	Campo removido da saída

Tabela 14– Problemas de qualidade e respetivo tratamento

5. Jobs

Um único job, job_transferencias, corre as duas transformações por ordem, envia o resultado por email e pára com erro se alguma etapa falhar.

5.1 Job Principal

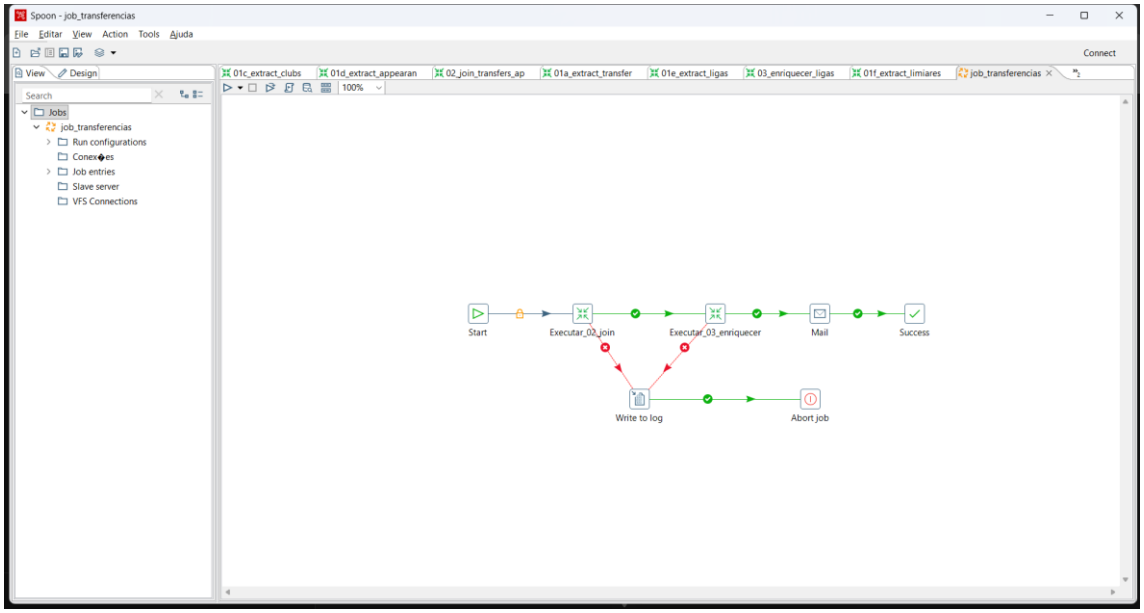


Figura 11– Job principal no Spoon

Nº	Entrada	Tipo	Função
1	Start	Start	Início do job
2	Executar_02_join	Transformation	Corre a transformação 02
3	Executar_03_enriquecer	Transformation	Corre a transformação 03
4	Mail	Mail	Envia o email com os ficheiros em anexo
5	Success	Success	Fim com sucesso
6	Write to log	Write to log	Regista a falha
7	Abort job	Abort job	Pára o job com erro

Tabela 15– Entradas do job principal

5.2 Tratamento de Erros

As duas transformações têm uma ligação vermelha (em caso de falha) para o Write to log e depois para o Abort job. Assim uma falha na 02 impede a 03 de correr sobre dados incompletos e fica registada.

5.3 Serviços Remotos: Email

O passo Mail usa o Gmail (smtp.gmail.com, porta 587, TLS) com uma palavra-passe de aplicação. O utilizador, a palavra-passe e o destinatário vêm das variáveis SMTP_USER, SMTP_PASSWORD e EMAIL_DESTINO, definidas em kettle.properties, e por isso não aparecem no repositório. O email leva em anexo os ficheiros gerados.

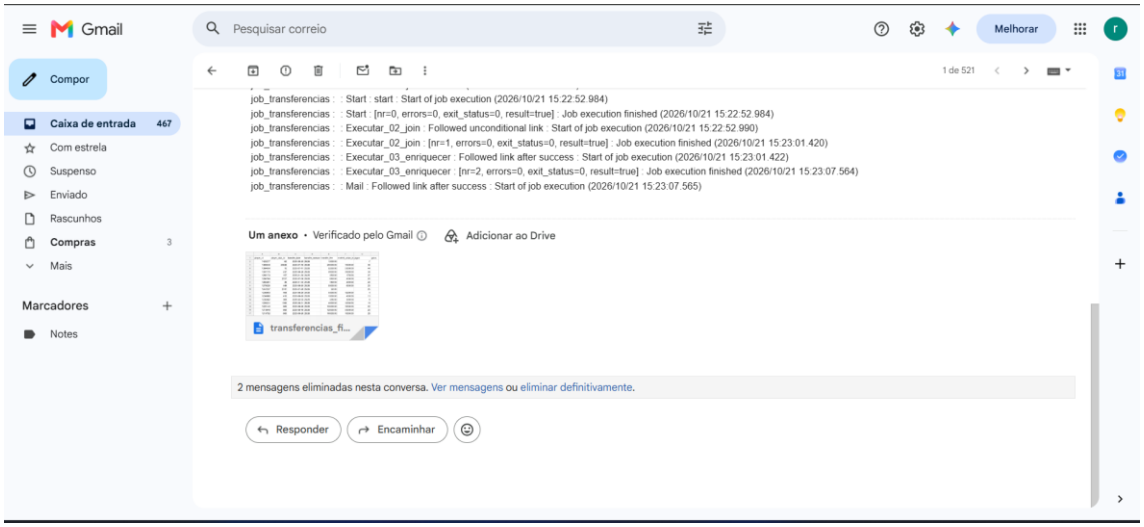


Figura 12– Email enviado pelo job

5.4 Logs

O job escreve o registo na consola do Spoon. A última execução terminou com Success e 0 erros, e carregou 8 430 linhas nas três saídas.

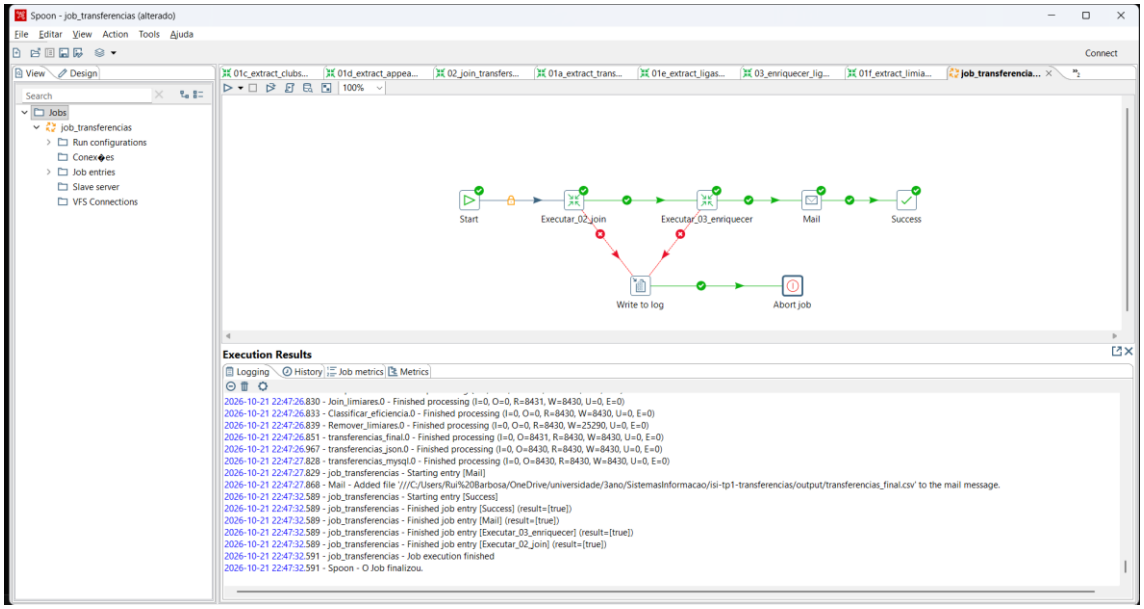


Figura 13– Execução do job

5.5 Agendamento

O job não está agendado: corre quando eu o executo no Spoon. Ficou como trabalho futuro.

6.Demonstração

O vídeo de demonstração (4 a 5 minutos) mostra o job a correr no Spoon, a tabela no MySQL e o email recebido.

https://drive.google.com/file/d/1gN69u3x7Osel6qRizAWxtm-s8E_I47Qh/view?usp=drive_link

6.1 Dashboard

Para ler o resultado de forma visual, construí um dashboard no Power BI Desktop, a partir do ficheiro output/transferencias_final.csv. O dashboard tem quatro visuais:

- **Total de transferências:** um cartão com a contagem de jogadores, que mostra 8 430.
- **Classificação:** um gráfico de colunas com o número de transferências em cada classe, de Sem contribuições a Muito fraca.
- **Contribuições por posição:** um gráfico de colunas com a média de golos e assistências no primeiro ano, por posição.
- **Custo por liga:** um gráfico de barras com as dez ligas onde cada golo ou assistência custou mais, em média.

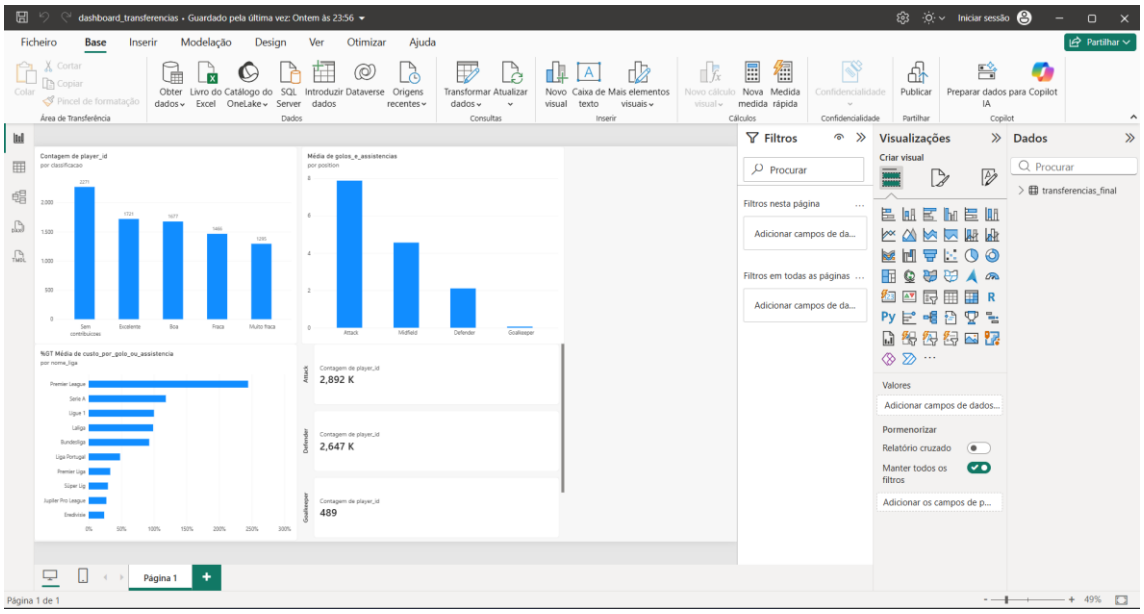


Figura 14– Dashboard no Power BI

5Os campos custo_por_jogo, valorizacao e custo_por_golo_ou_assistencia têm decimais com ponto, por isso foi preciso convertê-los no Power Query com a localidade Inglês (Estados Unidos).

O dashboard não se atualiza sozinho: depois de o job gerar um novo CSV, basta clicar em Atualizar no Power BI para os gráficos refletirem os dados novos. O ficheiro .pbix fica guardado na pasta docs/.

7. Conclusão e Trabalhos Futuros

7.1 Conclusão

O trabalho cumpre o objetivo: um job do Pentaho lê quatro CSV, um XML e um YAML, calcula o custo de cada golo ou assistência no primeiro ano de 8 430 transferências, classifica-as e entrega o resultado em CSV, JSON e MySQL, com email no fim. O processo corre em qualquer computador, porque usa caminhos relativos e guarda as credenciais fora do Git.

Os resultados têm limites que é preciso ter presentes: os limiares do YAML são arbitrários, a valorização compara valores de épocas diferentes e a classificação só olha para golos e assistências, o que penaliza defesas e guarda-redes.

7.3 Trabalhos Futuros

- Associar liga aos 85 clubes que ficaram sem código (o clubs.csv só tem 796 clubes) e completar o ligas.xml.
- Escolher os limiares do YAML com base na distribuição real dos custos.
- Comparar a valorização em valores da mesma época.
- Guardar mais de uma transferência por jogador e clube (o Stream lookup fica com uma).
- Escrever o log num ficheiro e numa tabela log_job.
- Agendar o job e acrescentar uma transformação com Table input, que leia a tabela e exporte as dez transferências mais eficientes.

8. Referências

- dcaribou/transfermarkt-datasets – conjunto de dados usado, com informação do Transfermarkt.
- Pentaho Data Integration – documentação dos passos e do job.
- MySQL Reference Manual – tipos de dados e instruções SQL.